

MASTER 2 PSI 2022-2023

DEVOIR DE MAISON MACHINE LEARNING

La détection d'objet par machine learning est une technique de traitement de l'image qui consiste à utiliser des algorithmes de reconnaissance de pattern pour détecter et classer des objets dans une image ou une vidéo.

L'objectif de ce TP est faire une classification d'image par machine learning, nous avons un lot d'image représentant des chiffres 5 ou 9 illuminés réciproquement par une LED ou une source thermique. Ces scènes sont acquises au moyen d'un spectro-imageur qui enregistre sur l'ordre 0 une image des chiffres et dans les ordres 1 le spectre diffracté de ces chiffres. Nous traiterons ce Tp sur 3étapes .

1^{er} ETAPE :

Cette première étape consistait à segmenter automatiquement l'ordre 0 et les ordres 1 de diffraction sur l'ensemble de ces images. Pour ce faire nous avons à l'aide d' ImageJ déterminer les rectangles englobant les différents ordres, à partir de ces derniers nous avons réalisé des crop qui permettent d'obtenir les images suivantes:

Les figures 1 et 3 représentent les images issuent de l'illumination respectivement des sources thermiques et des LED que nous utiliserons dans un premier temps comme donnés d'entraînement.

Ensuites les figures 2 et 4 représentent les images issuent de l'illumination respectivement des LED et des sources thermiques que nous utiliserons dans un premier temps comme données de test.




Figure1 : crop de l'ordre 0(gauche) et l'ordre1(droite) du chiffre 5 (issus des sources thermiques)




Figure2 : crop de L'ordre 0(gauche) et l'ordre1(droite) du chiffre 5(LED)




Figure3 : crop de l'ordre 0(gauche) et l'ordre1(droite) du chiffre 9(LED)





Figure4 : crop de l'ordre 0(gauche) et l'ordre1(droite) du chiffre 9 (issus des sources thermiques)

ETAPE 2 :

Pour étudier les images de l'ordre 1 nous l'avons applati (somme des colonnes) pour étudier leur intensité suivant les longueurs d'onde, soit une représentation du spectre. Nous les représentons dans les figures 5 à 8.

Représentation spectrales des images de l'ordre0 pour l'entraînement (TRAIN)



Acti

Figure5 : Spectre de l'ordre 1 des chiffres 5

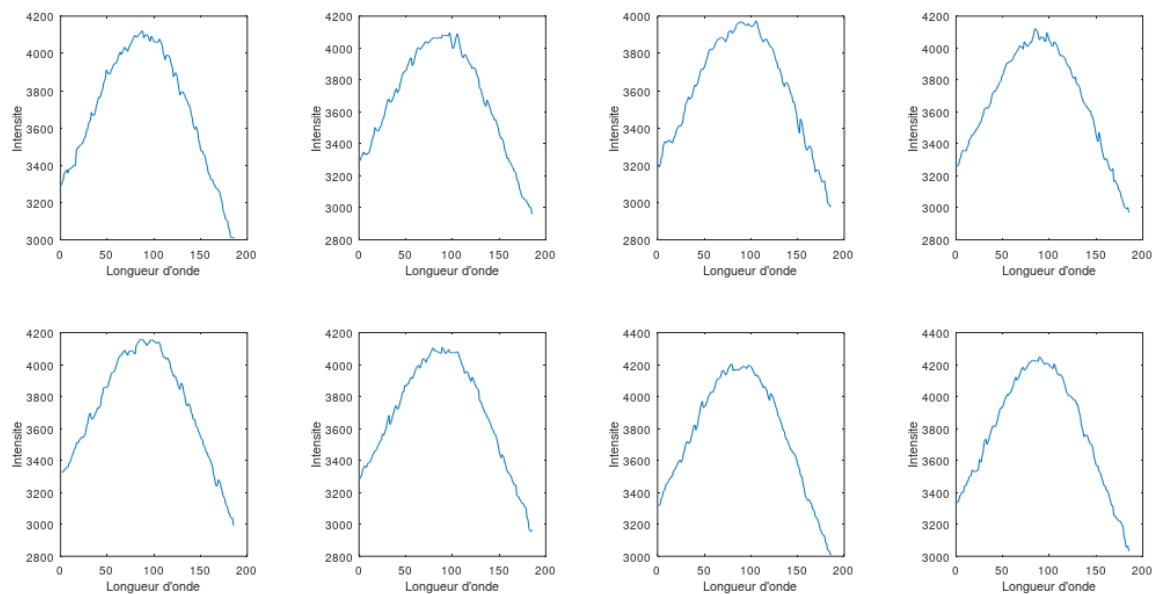


Figure6 : Spectre de l'ordre 1 des chiffres 9

Images pour les tests

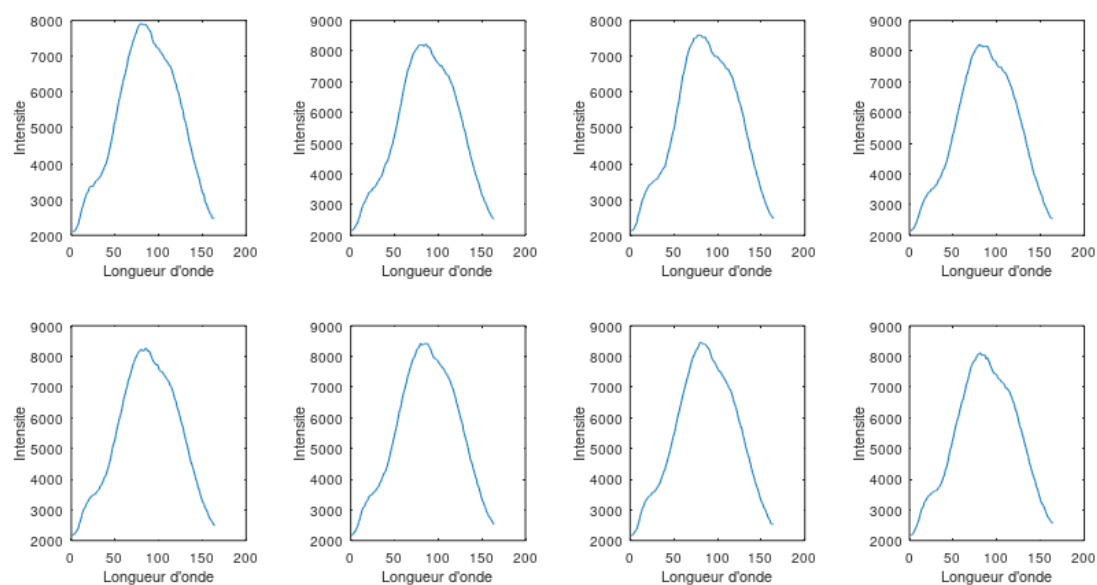


Figure7 : Spectre de l'ordre1 des chiffres 5




Figure8 : Spectre de l'ordre 1 des chiffres 9

Dans cette deuxième étape il est question de développer des descripteurs (features) nous permettant de distinguer la différence entre nos deux chiffres. L'ordre 0 donne des informations spatiales et l'ordre 1 des informations spectrales.

Pour les features spectrales nous avons utilisé des grandeurs statistiques telles que la Variance, le Maximum, le Minimum, l'Ecart-type, la Moyenne qui vont permettre de caractériser l'écriture des 5 et des 9.

Pour ce qui est des features spatiales nous avons également utilisé des grandeurs statistiques : telles que l'entropie, la Variance sur la somme lignes et sur la somme des colonnes, la Variance sur la moyenne des lignes et sur la moyenne des colonnes, le moment et le kurtosis,

La moyenne : c'est la valeur centrale de la distribution des données, calculée en prenant la somme de toutes les valeurs et en les divisant par le nombre de valeurs.

L'écart-types : c'est une mesure de la dispersion ou de la variabilité des données autour de la moyenne. Plus l'écart-type est élevé, plus les valeurs des données sont dispersées.

Le mode : c'est la valeur qui apparaît le plus fréquemment dans la distribution des données

Le minimum et le maximum : ce sont les valeurs les plus faibles et les plus élevées de la distribution des données.

L'entropie est une mesure de l'incertitude ou de la variabilité des données d'une image ou d'une distribution de probabilité. Dans notre cas elle est utilisée pour quantifier la quantité d'information ou de surprise contenue dans une image.

Après implémentation nous obtenons les représentations des images suivant les features présentés au préalable, nous les regroupons par 3 dans chaque espace défini :

Représentation des images de TRAIN en fonction des features




Figure10:Nuage de point des données suivant la Variance ligne, Variance globale, Variance moyenne colonne

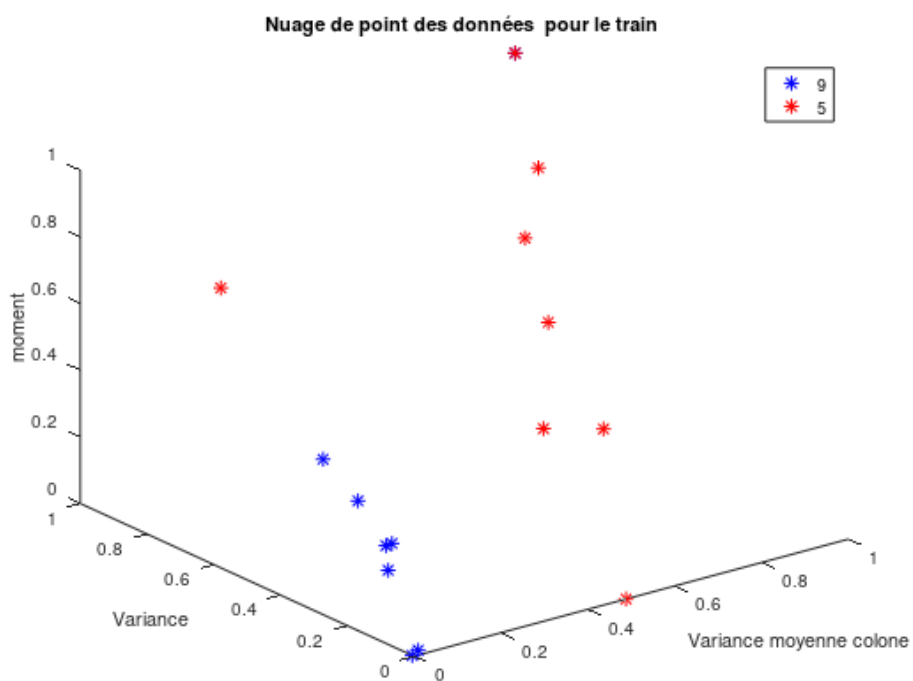


Figure11 :Nuage de point des données suivant Moment, Variance globale, Variance moyenne colonne




Figure12: Nuage de point des données Variance spectrale, Variance colonne, Variance ligne

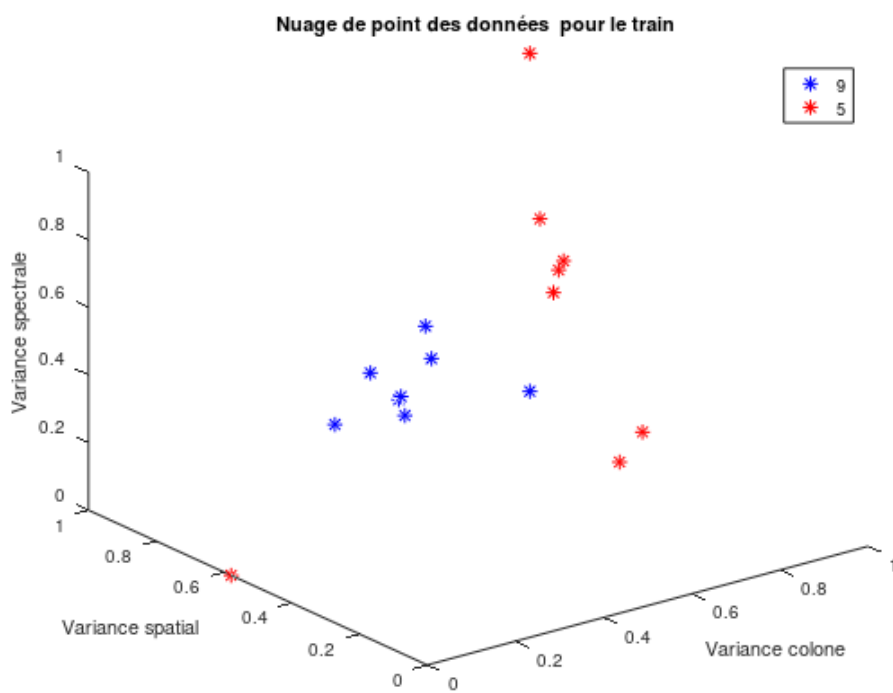


Figure13: Nuage de point des données suivant Variance spectrale, Variance spatiale, Variance colonne

Représentation des images de TEST en fonction des features




Figure14: Nuage de point des données suivant la variance globale , variance sur ligne ,variance sur colonne

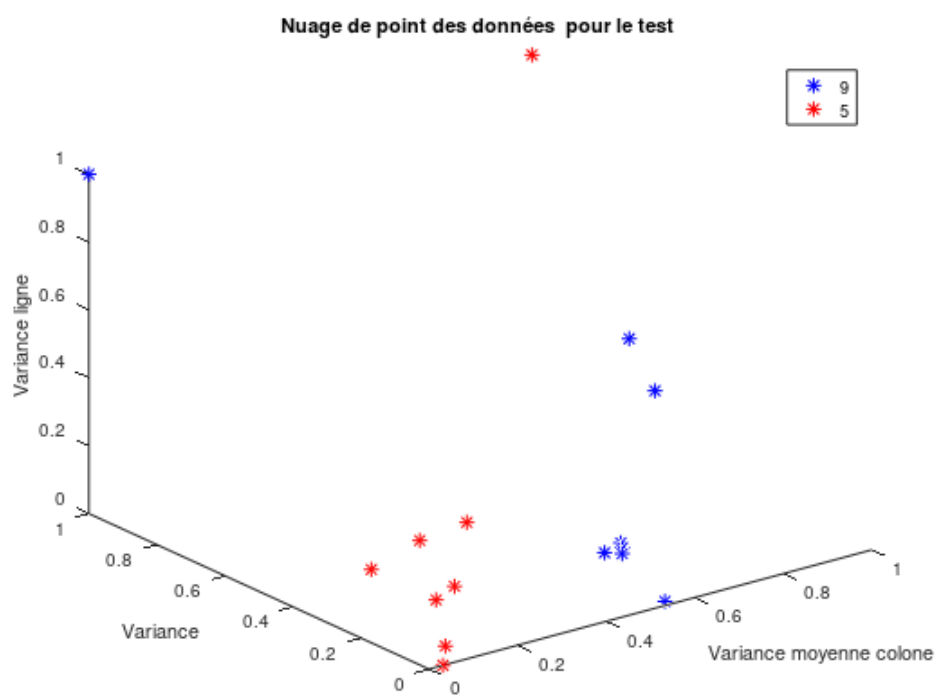


Figure15: Nuage de point des données suivant la Variance ligne, Variance globale, Variance moyenne colonne

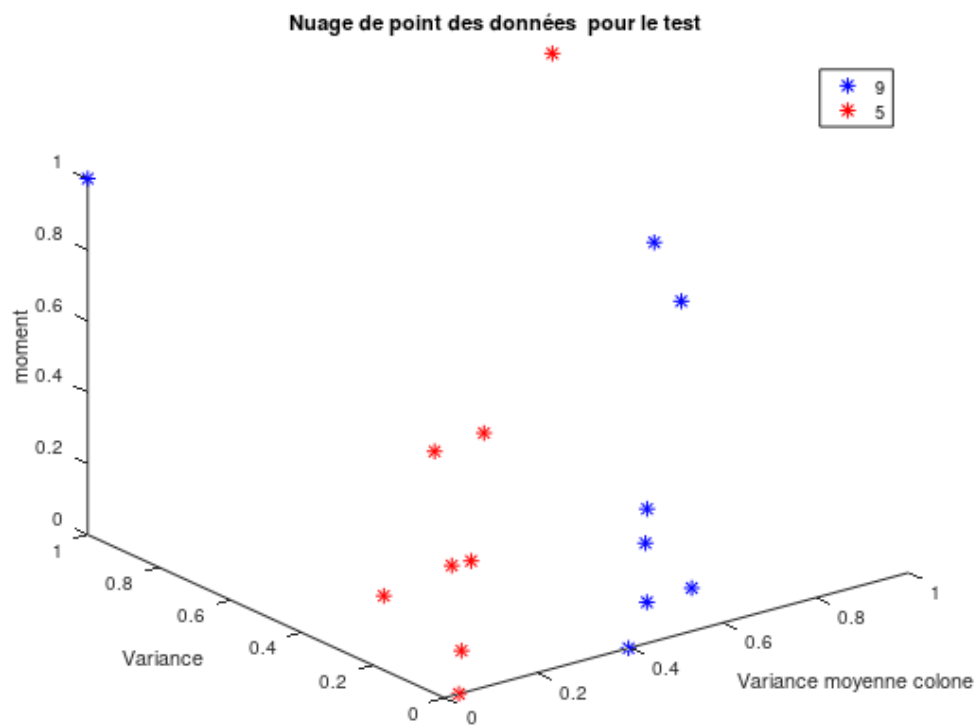


Figure16 : Nuage de point des données suivant Moment, Variance globale, Variance moyenne colonne

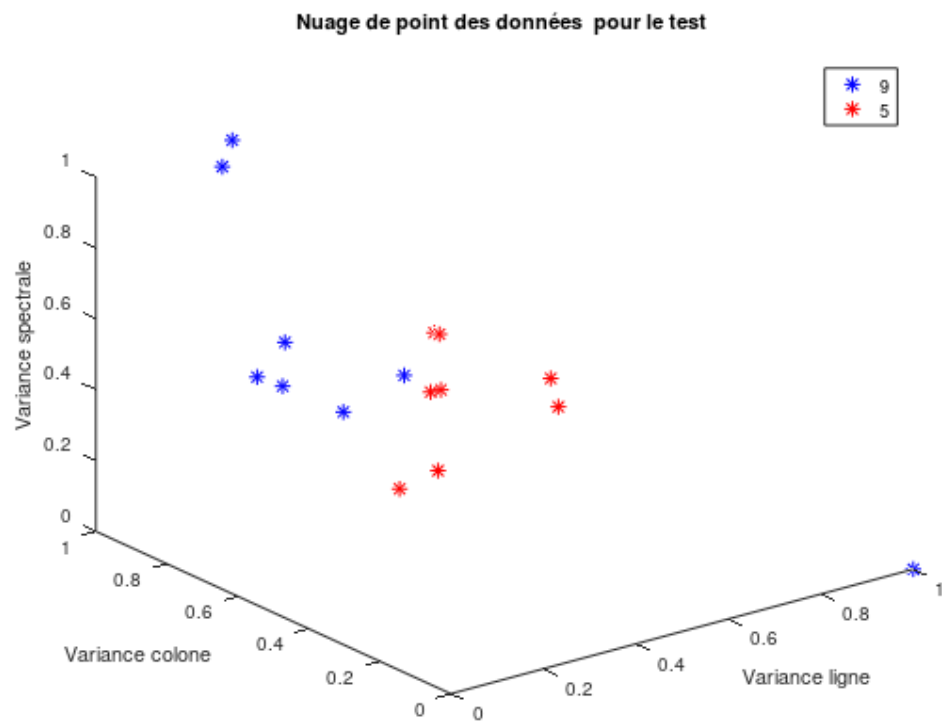


Figure17: Nuage de point des données Variance spectrale, Variance colonne, Variance ligne




Figure18 : Nuage de point des données suivants Variance spectrale, Variance spatiale, Variance colonne

Après une analyse des représentations des nuages de points avec les images de train (figure 9 à 13) dans l'espace des features, nous optons d'utiliser :

2 features spatiales : **la variance sur les colonnes et la variance globales de l'image et 1**
 features spatiale : **la variance du spectre** : car elles ont permis de presque bien séparer les classes des 5 et des 9. Ainsi nous reproduisons avec toutes les features les images de test (figure 14 à 18).

ETAPE 3 :

Applications du KNN :

pour chacune des points (représentant les images de test) dans l'espace des features choisis nous calculons les k plus proches voisins par rapport aux nuages de points des trains : la classe la plus représentée dans k est celle prédite.

Pour k=1,2,3 nous regroupons les différentes prédictions dans les tableaux suivants :

***Ainsi pour k= 3**

Nous prédisons pour les 8 images des tests des chiffres 5 :

9	9	5	9	9	9	9	9
---	---	---	---	---	---	---	---

Nous prédisons pour les 9 :

9	9	5	9	9	9	5	5
---	---	---	---	---	---	---	---

***Pour k= 5**

Nous prédisons pour les 5 :

5	9	5	9	9	9	9	5
---	---	---	---	---	---	---	---

Nous prédisons pour les 9 :

9	9	5	5	5	9	9	9
---	---	---	---	---	---	---	---

***Pour k= 7**

Nous prédisons pour les 5 :

5	5	5	5	5	5	9	5
---	---	---	---	---	---	---	---

Nous prédisons pour les 9 :

9	9	5	9	9	9	9	9
---	---	---	---	---	---	---	---

Matrice de confusion

*** Pour K=3**

Vérité terrain\ Prédiction	Positif	Négatif
Positif	6/16	10/16

***Pour K=5**

Vérité terrain\ Prédiction	Positif	Négatif
Positif	8/16	8/16

***Pour K=7**

Vérité terrain\ Prédiction	Positif	Négatif
Positif	14/16	2/16

A l'aide des matrices de confusions nous obtenons la courbe en ROC qui décrit le taux des vrai positif en fonction des faux positif obtenu sur différent valeur du paramètre k.

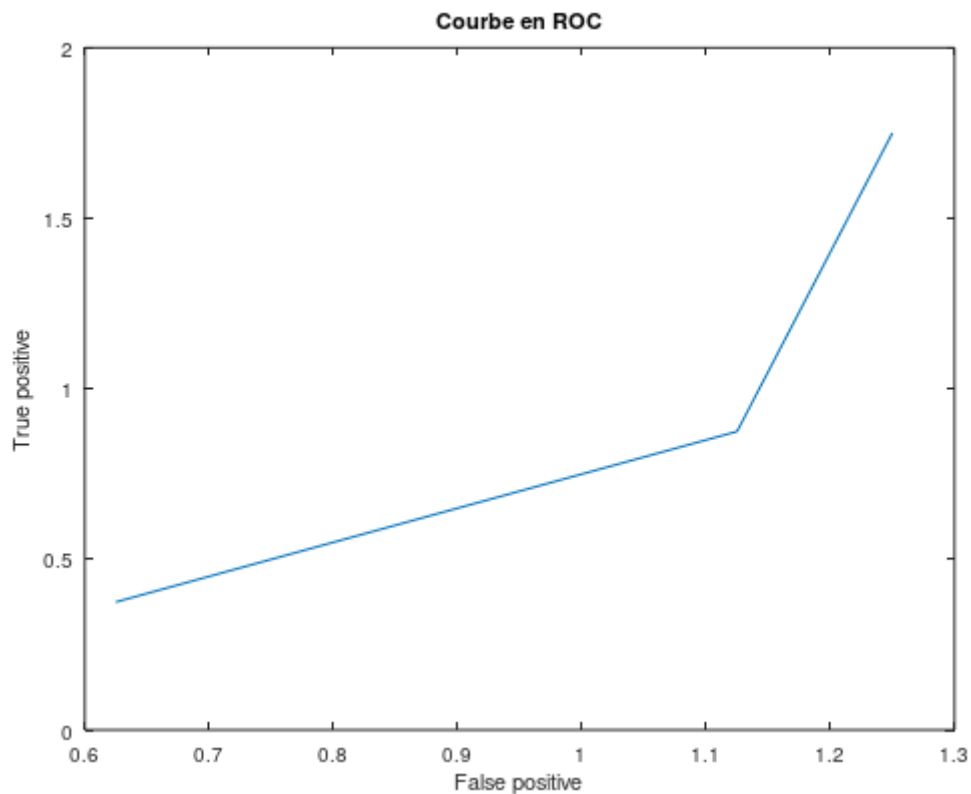


Figure19 : la courbe roc

Sur la courbe en ROC nous remarquons bien que plus K augmente plus nous avons de bonne détection, et peu de mauvaises détections. En effet nous voyons bien que sur le graphique dans un

premier temps la pente de la 1ere moitié du graphique est grande (montrant la faible variation des True positive contre les False positives qui évoluent relativement plus vite) puis sur l'autre moitié du graphique la pente est faible montrant la faible variation des False positive contre les True positives qui évoluent plus vite.

Les valeurs des K nous les choisissons impaires pour éviter les prédictions de à par égale pour les 2 classes de chiffre, ce qui correspondrait à aucune prédiction.

Conclusion : ce tp nous a permis de d'explorer les étapes de segmentations et de classification et surtout de développer par nous même des features pour caractériser nos images pour pouvoir les distinguer leur contenu uns des autres.